Ключевые статьи области

Мотивация

Интуитивно понятно, что такое ключевая в области статья. Но формализовать это понятие трудно, а правильного ответа не существует. При этом задача важная: стандартный способ находить важные работы упростил бы жизнь исследователям, которые входят в новую область, а также помог бы при независимой экспертизе, например при оценке патентов или научных проектов.

В этом задании вы выберете интересную вам область, сами решите, что значит «ключевая статья», превратите это определение в способ ранжирования статей и найдёте 3–5 ключевых работ. Главное здесь — не список, а обоснование того, почему ваш метод разумен.

> ✏️ **Политика использования ИИ**
>
> ИИ можно использовать для работы с данными и API сайтов, а также как **один из** источников для проверки результата: например, спросить ассистента о ключевых работах области и сравнить его ответ со своим. Выбор определения и обоснование итогового списка вы делаете сами.

---

1. Что такое ключевая статья

Ниже три возможных определения. Выберите одно из них, совместите несколько или предложите своё, но обязательно обоснуйте выбор применительно к вашей области.

1. **Статья, задавшая тренд.** После её публикации резко выросло число работ по теме, которые на неё ссылаются. Тренд может быть **отложенным**: статья годами почти не цитируется, а потом становится знаменитой.
2. **Статья с важной для области идеей.** Она открыла новое направление, а не просто улучшила предыдущие результаты. Признак такой работы: её цитируют *вместо* тех работ, на которые ссылается она сама, то есть она заменила собой предшественников.
3. **Статья, известная за пределами науки.** На неё часто ссылаются СМИ, энциклопедии, соцсети, патенты или учебники.

---

2. Граф цитирований

Удобно думать о статьях как о вершинах **графа цитирований** $G = (V, E)$.

Ниже несколько способов превратить граф в ранжирование. Это не готовые ответы: у каждого способа есть недостатки, и их нужно учитывать.

Число цитирований

$$c(v) = |\{u : (u, v) \in E\}| \quad (\text{входящая степень вершины}).$$

Самый простой показатель. Недостатки: старые статьи успели накопить больше ссылок, а обзоры и методические работы часто цитируют больше, чем статьи с новыми идеями.

PageRank

Алгоритм, которым Google ранжировал веб-страницы, придуман по мотивам анализа цитирований. Идея: статья важна, если на неё ссылаются важные статьи.

$$PR(v) = \frac{1 - d}{|V|} + d \sum_{(u,v) \in E} \frac{PR(u)}{c_{\text{out}}(u)},$$

где $c_{\text{out}}(u)$ — число ссылок статьи u, а $d \approx 0{,}85$. Значения находятся итерациями, пока не перестанут меняться.

Подумайте, почему в графе цитирований PageRank может вести себя иначе, чем в вебе. Статьи ссылаются только на более старые работы, так что в графе нет циклов.

Индекс того, насколько статья прорывная

Для статьи v рассмотрим все более поздние работы, которые ссылаются на v или на работы, процитированные в v:

- n_i — число работ, которые цитируют v, но не цитируют ни одну из её ссылок;
- n_j — число работ, которые цитируют и v, и хотя бы одну из её ссылок;
- n_k — число работ, которые цитируют ссылки v, но не саму v.

$$CD(v) = \frac{n_i - n_j}{n_i + n_j + n_k} \in [-1, 1].$$

Значение около $+1$ означает, что статья затмила своих предшественников: её цитируют вместо них. Значение около -1 означает, что статья развивает существующую линию: её цитируют вместе с предшественниками.

Другие подходы

Можно придумать свой показатель или совместить несколько. Например, цитирования на год после публикации, рост числа цитирующих статей, упоминания в обзорах, Altmetric-показатель внимания в интернете.

---

3. Что нужно сделать

1. **Задайте границы области.** Как вы решаете, какие статьи относятся к области? Например: по ключевым словам, по концепту в OpenAlex, по категории arXiv или как все статьи, которые цитируют один-два обзора по теме. Соберите не меньше 100 кандидатов.
2. **Выберите определение** ключевой статьи из раздела 1 или предложите своё.
3. **Постройте не меньше двух разных ранжирований** кандидатов. Одно из них - число цитирований, второе - способ, который соответствует вашему определению: PageRank, индекс, оценивающий прорыв, или ваш собственный.
4. **Нарисуйте граф цитирований** вашей области или его части и отметьте на нём ключевые статьи.
5. **Выберите 3-5 ключевых статей** и обоснуйте выбор.
6. **Проверьте результат по двум независимым источникам.** Подойдут обзорные статьи, учебники, премии «проверка временем» (Test of Time Awards) на конференциях, статьи Википедии, ИИ-ассистент или мнение эксперта. Совпадает ли ваш список с ними? Если нет, почему?

---

4. Источники данных

Источник	Что даёт
OpenAlex API - https://api.openalex.org (бесплатно, без ключа)	Статьи, ссылки (*referenced_works*), цитирования по годам (*counts_by_year*)
Semantic Scholar https://www.semanticscholar.org	Цитирования, отметка «влиятельных» цитирований, API
Connected Papers, **Litmaps**, **ResearchRabbit**	Визуализация графа цитирований вокруг выбранной статьи
Google Scholar	Число цитирований
Altmetric - https://www.altmetric.com	Упоминания статей в СМИ и соцсетях

Можно пользоваться любыми другими открытыми источниками, но каждый из них нужно назвать в отчёте.

---

5. Что сдать

Короткий отчёт (2-3 страницы)

В отчёте следует указать:

- **область:** как вы задали её границы;
- **определение** ключевой статьи и почему оно разумно для вашей области;
- **методы:** какие ранжирования вы построили и чем различаются их результаты;
- **граф цитирований** с отмеченными ключевыми статьями;
- **итог:** 3–5 ключевых статей, по каждой - в двух-трёх предложениях, почему она ключевая;
- **проверка:** сравнение с двумя независимыми источниками.

Код, если вы его писали.

---

6. Устная беседа (7 минут)

Во время беседы расскажите про то, как определяли важность статьей, как искали статьи и чем пользовались при поиске.